Machine Learning Engineer Nanodegree

Capstone Project

Eliézer F. Bourchardt

January 21st, 2018

I. Definição

Visão Geral do Projeto

A reforma política brasileira é um assunto que constantemente está na mídia. As eleições no Brasil são as mais caras do mundo, onde o sistema eleitoral, adotado pelo país desde 1945, obriga o candidato a disputar votos em uma área muito grande. Além disso, gastos elevados podem resultar em sucesso nas eleições, pela fragilidade de boa parte do eleitorado, suscetível à influência do poder econômico e das máquinas administrativas[1].

A utilização do poder econômico atrelado a eleição de candidatos é considerado “voto de cabresto”, onde no passado era uma prática explícita, hoje é realizada pela compra de votos[2]. Para alimentar essa máquina o político se utiliza de doações realizadas a ele, favorecendo assim a corrupção[3].

Todos os datasets utilizados neste projeto são disponibilizados pelo TSE[4]. Utilizarei apenas os dados da eleição de 2014, filtrando apenas candidatos a deputado federal, estadual e distrital. Também utilizarei o dataset *Electoral Donations in Brazil* disponibilizado no repositório do Kaggle por Felipe Leite Antunes.

[1] https://www12.senado.leg.br/noticias/materias/2014/09/15/eleiassaues-no-brasil-sapso-as-mais-caras-do-mundo
[2] https://pt.wikipedia.org/wiki/Voto_de_cabresto
[3] http://politica.estadao.com.br/noticias/geral,as-10-empresas-que-mais-doaram-em-2014-ajudam-a-eleger-70-da-camara,1589802
[4] http://www.tse.jus.br/eleitor-e-eleicoes/estatisticas/repositorio-de-dados-eleitorais-1/repositorio-de-dados-eleitorais

Declaração do Problema

As eleições de 2014 tiveram 21.101 candidatos a deputado estadual, federal e distrital. Destes, 1.572 foram eleitos, o que dá uma porcentagem de 7,45% de eleitos. Também houve um total de R$ 2,4 bilhões em doações a candidatos, provenientes de pessoas físicas e jurídicas. Estes candidatos também declararam um total de R$ 9,1 bilhões em bens[5]. Isto demonstra o peso econômico das eleições.

Também existem poucas pesquisas de intenção de votos para deputados e as realizadas normalmente não funcionam muito bem[6]. Isso acontece porque há um grande número de candidatos e porque existe um cálculo para definir os eleitos, onde muitas vezes o mais votado não é eleito[7].

O poder econômico relacionado ao poder político é um grande entrave para a reforma política brasileira. Mesmo com alterações nas regras para a próxima eleição, é provável que esta relação mantenha-se, sendo possível utilizar o mesmo modelo, talvez com algumas alterações.

Para este problema de classificação utilizarei como dados de entrada arquivos csv (disponibilizado pelo TSE) com os dados já estruturados. Estes dados consistem em características dos candidatos (idade, sexo, raça/cor, etc) e dados financeiros (bens declarados e doações recebidas).

Estes dados estão em datasets separados que deverão ser unidos para realizar o tratamento dos dados (remoção e criação de novos atributos, tratamento de dados faltantes, outliers). O próximo passo é realizar uma análise exploratória para entender melhor estes dados.

Depois de separar os dados em treino e teste, já é possível realizar os testes iniciais com alguns classificadores para verificar qual apresenta melhor desempenho. Estes classificadores terão como saída esperada duas classe: eleito (1) e não eleito (0). Por fim, realizar os ajustes finos no modelo com o objetivo de obter uma melhor performance nos dados de testes em comparação com o benchmark. Se necessário, todas as etapas podem ser repetidas, para corrigir eventuais problemas ou para melhorar o dataset.

Métricas

Como este é um problema de classificação em um dataset desbalanceado, onde apenas 7,45% dos dados pertencem a classe de candidatos eleitos, é necessário considerar isto para que a métrica reflita efetivamente a qualidade do modelo.

---

[5] Análise preliminar realizada no dataset.

[6] https://www.jornalopcao.com.br/bastidores/pesquisas-de-intencao-de-votos-para-deputado-federal-e-estadual-nao-sao-uteis-para-densidade-eleitoral-149/

[7] http://g1.globo.com/politica/eleicoes/2014/noticia/2014/09/entenda-como-e-feito-o-calculo-para-eleicao-de-um-deputado.html

Para avaliar um classificador corretamente é importante compreender a *matriz de confusão*, que é uma espécie de tabela de contingência. Uma matriz de confusão separa as decisões tomadas pelo classificador, tornando explícito como uma classe está sendo confundida com a outra[8].

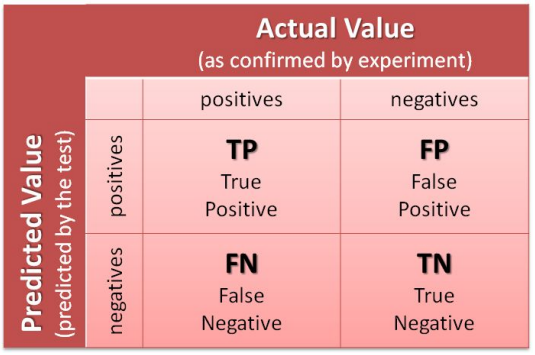

Multi Class Confusion Matrix[9]

F1 Score

Para calcular o F1 Score é necessário calcular primeiramente duas medidas: *Precisão* e *Recall*.

A Precisão é a medida da quantidade de amostras classificadas como positivas que são realmente positivas:

$$\text{Precision} = \frac{\text{TP}}{\text{TP+FP}}$$

Recall, por outro lado, mede quantas das amostras positivas são capturadas pelas previsões positivas:

$$\text{Recall} = \frac{\text{TP}}{\text{TP+FN}}$$

A precisão é usada como métrica de desempenho quando o objetivo é limitar o número de falso-positivo, já Recall é usado como métrica de desempenho quando precisamos identificar todas as amostras positivas; isto é, quando é importante evitar falsos negativos.

Sempre devemos olhar as medidas de Recall e Precisão conjuntamente. Você pode obter um Recall perfeito se você prevê que todas as amostras pertençam à classe positiva - não haverá falsos negativos e também não haverá negativos verdadeiros. No entanto, prever todas as amostras como positivas resultará em muitos falsos positivos e, portanto, a precisão será muito baixa. Por outro lado, se você encontrar um modelo que prevê

[8] Foster Provost & Tom Fawcett. Data Science para Negócios. Página 189.
[9] Abbas Manthiri S: https://www.mathworks.com/matlabcentral/fileexchange/60900-multi-class-confusion-matrix?s_tid=gn_loc_drop

apenas o ponto de dados único, é mais seguro quanto positivo e o restante como negativo, então a precisão será perfeita (assumindo que esse ponto de dados é de fato positivo), mas o Recall será muito baixo[10].

O F1 Score é a média harmônica entre a Precisão e o Recall, onde uma pontuação F1 atinge seu melhor valor em 1 e pior pontuação em 0. A contribuição relativa de precisão e recall para a pontuação F1 é igual[11].

$$F1 = 2 * (Precision + Recall) / (Precision + Recall)$$

AUC – Area Under the ROC Curve

Receiver Operating Characteristic, ou simplesmente ROC Curve, é um gráfico que ilustra o desempenho de um sistema classificador binário, pois seu limiar de discriminação é variado. É criado traçando a fração de positivos verdadeiros dos positivos (TPR = taxa positiva verdadeira) versus a fração de falsos positivos fora dos negativos (FPR = taxa de falso positivo), em várias configurações de limiar. TPR também é conhecido como sensibilidade, e FPR é um menos a especificidade ou taxa negativa verdadeira[12].

A AUC mede a área sob uma curva formada pelo gráfico entre a taxa de exemplos positivos, que realmente são positivos, e a taxa de falsos positivos. O desempenho do modelo é medido em vários pontos de corte, não necessariamente atribuindo exemplos com probabilidade maior que 50% para a classe positiva, e menor, para a classe negativa

II. Analysis

Data Exploration

Todos os datasets utilizados neste projeto são disponibilizados pelo TSE[13]. Utilizarei apenas os dados da eleição de 2014, filtrando apenas candidatos a deputado federal, estadual e distrital. Também utilizarei o dataset *Electoral Donations in Brazil* disponibilizado no repositório do Kaggle por Felipe Leite Antunes.

A seguir listo os datasets utilizados e suas referências:

1) consulta_cand_2014.zip[14] - Possui as informações pessoais de todos os candidatos, separado por UF. Este dataset possui os dados de 21.101 candidatos.
    a) Dos atributos existentes, utilizarei nove, sendo eles:

[10] Andreas C. Müller and Sarah Guido. Introduction to Machine Learning with Python - A guide for data scientists, páginas 284 e 285.
[11] http://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html
[12] https://en.wikipedia.org/wiki/Receiver_operating_characteristic
[13] http://www.tse.jus.br/eleitor-e-eleicoes/estatisticas/repositorio-de-dados-eleitorais-1/repositorio-de-dados-eleitorais
[14] http://agencia.tse.jus.br/estatistica/sead/odsele/consulta_cand/consulta_cand_2014.zip

i) Categóricos: CODIGO_CARGO, CODIGO_OCUPACAO, IDADE_DATA_ELEICAO, CODIGO_SEXO, COD_GRAU_INSTRUCAO, CODIGO_ESTADO_CIVIL, CODIGO_COR_RACA.
ii) Númerico: DESPESA_MAX_CAMPANHA.
iii) Variável alvo: DESC_SIT_TOT_TURNO - Com os seguintes valores:
- "ELEITO POR QP", "ELEITO POR MEDIA" = 1.
  - Total de eleitos 1.572.
- "NÃO ELEITO", "SUPLENTE" = 0.
  - Total de não eleitos: 19.529.

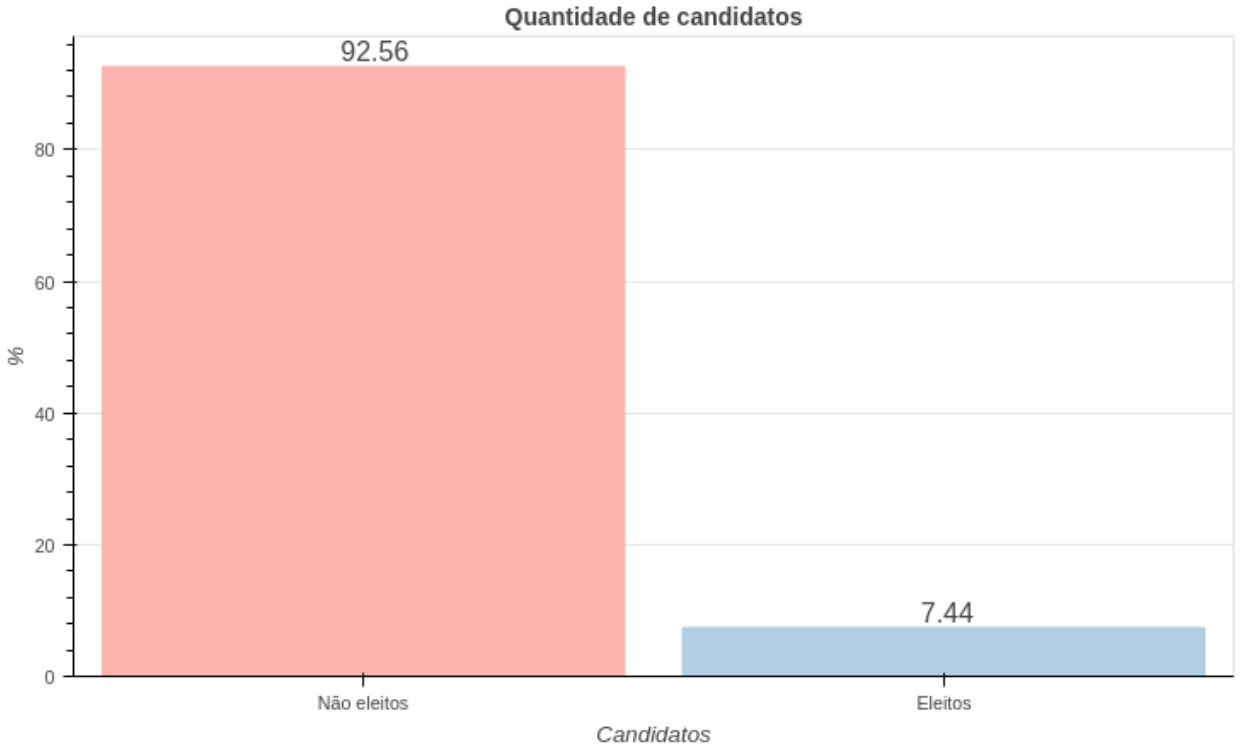

2) bem_candidato_2014.zip[15] - Possui as informações dos bens declarados pelos candidatos, separado por UF. Deste dataset irei utilizar apenas a soma dos valores declarados por cada candidato.
3) receitas_candidatos_2014_brasil.txt[16] - Lista de doações aos candidatos. Utilizarei o valor das receitas doadas para cada candidato, bem como o doador e tipo de doador.
   a) Para separar as receitas por setores econômicos utilizei a tabela de classes de CNAE, que é um arquivo tipo XLS disponibilizado pelo IBGE[17]. Foi necessário realizar uma limpeza nesta dataset para vincular com o dataset das listas de doações.

[15] http://agencia.tse.jus.br/estatistica/sead/odsele/bem_candidato/bem_candidato_2014.zip
[16] https://www.kaggle.com/felipeleiteantunes/electoral-donations-brazil2014/downloads/receitas_candidatos_2014_brasil.txt
[17] https://concla.ibge.gov.br/classificacoes/download-concla.html

b) Foi possível mapear todos os setores econômicos, exceto um, onde foi necessário atribuir o setor manualmente.

Os datasets 1 e 2 são disponibilizados em arquivos compactados. Estes arquivos contêm os dados separados por UF. Dessa forma é necessário realizar o processo de consolidação destes arquivos em 2 datasets. Já o dataset 3 já está disponibilizado de forma consolidada.

O dataset final ficou com os 41 atributos:

['CODIGO_CARGO', 'CODIGO_OCUPACAO', 'IDADE_DATA_ELEICAO', 'CODIGO_SEXO', 'COD_GRAU_INSTRUCAO', 'CODIGO_ESTADO_CIVIL', 'CODIGO_COR_RACA', 'CODIGO_NACIONALIDADE', 'DESPESA_MAX_CAMPANHA', 'DESC_SIT_TOT_TURNO', 'VALOR_BEM', 'SETOR_A', 'SETOR_B', 'SETOR_C', 'SETOR_D', 'SETOR_E', 'SETOR_F', 'SETOR_G', 'SETOR_H', 'SETOR_I', 'SETOR_J', 'SETOR_K', 'SETOR_L', 'SETOR_M', 'SETOR_N', 'SETOR_O', 'SETOR_P', 'SETOR_Q', 'SETOR_R', 'SETOR_S', 'SETOR_NAO_IDENTIFICADO', 'TP_RECEITA_APLICACAO', 'TP_RECEITA_EVENTO', 'TP_RECEITA_FISICA', 'TP_RECEITA_INTERNET', 'TP_RECEITA_JURIDICA', 'TP_RECEITA_NAO_IDENTIFICADA', 'TP_RECEITA_OUTRO', 'TP_RECEITA_PARTIDO', 'TP_RECEITA_PROPRIO', 'VALOR_RECEITA']

Distribuídos da seguinte forma:

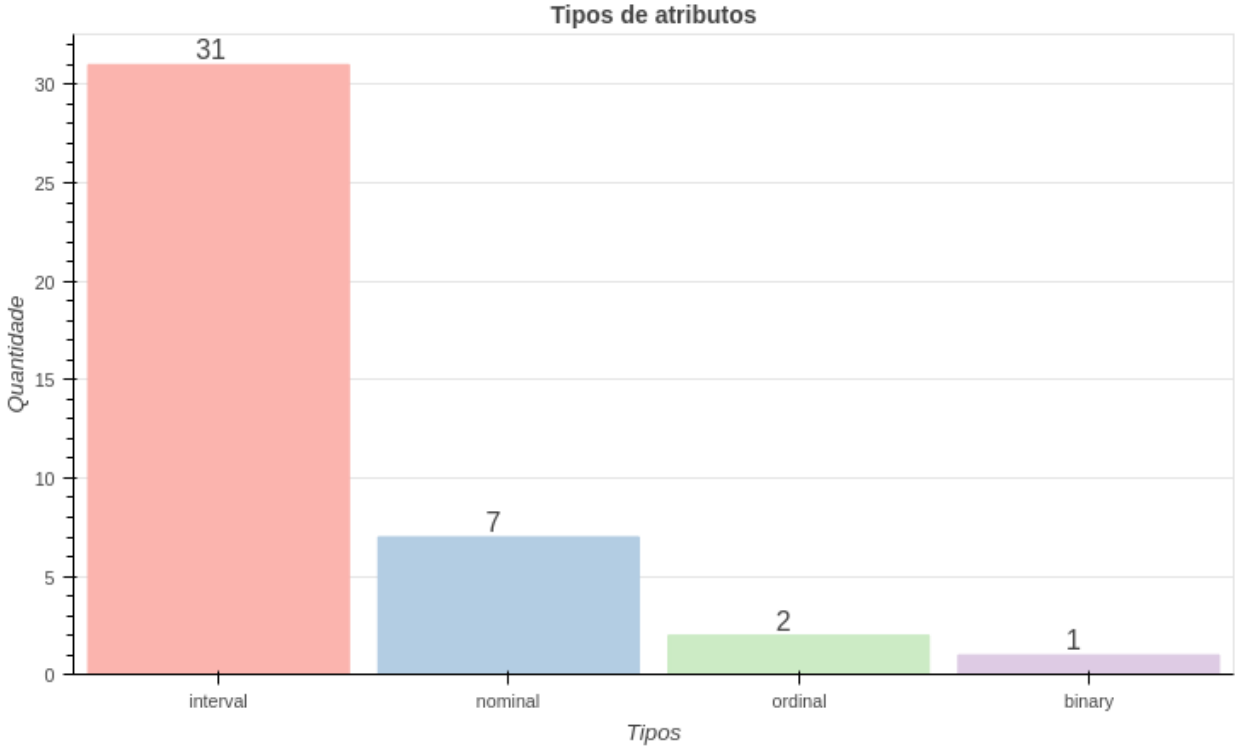

Dados faltantes

Como esperado, este dataset não possui quantidade significativa de dados faltantes. O atributo que mais possui dados faltantes é o valor dos bens, significando que estes

candidatos não possuem nada no nome (na teoria). Alguns poucos candidatos também não tiveram dinheiro investido de doações.

Outliers

Utilizei a função dataframe.describe() para ter uma visão geral de todos os atributos. Em geral o dataset possui valores dentro do esperado e alguns atributos com valores aparentemente altos.

	IDADE_DATA_ELEICAO	DESPESA_MAX_CAMPANHA	VALOR_BEM	valor_receita
count	21124.00	21124.00	21124.00	21124.00
mean	46.75	2759528.59	430926.83	114321.59
std	11.22	3933738.89	4912578.33	379515.13
min	20.00	0.00	0.00	0.00
25%	39.00	1000000.00	0.00	1020.22
50%	47.00	2000000.00	35376.29	6324.30
75%	54.00	4000000.00	283164.17	42983.44
max	91.00	90000000.00	610000000.00	6832480.98

- Candidato com a idade de 91 anos;
- Valor máximo declarado de bens R$ 610.000.000,00;
- Valor máximo próprio utilizado na campanha R$ 4.041.310,27;
- Valor máximo recebido do partido R$ 5.769.682,00;
- Valor máximo recebido em doação R$ 6.832.480,98.

Para visualizar melhor estes atributos, utilizei o gráfico *boxplot*.

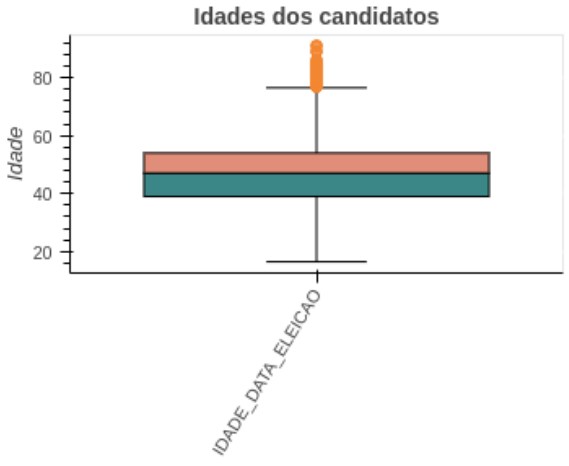

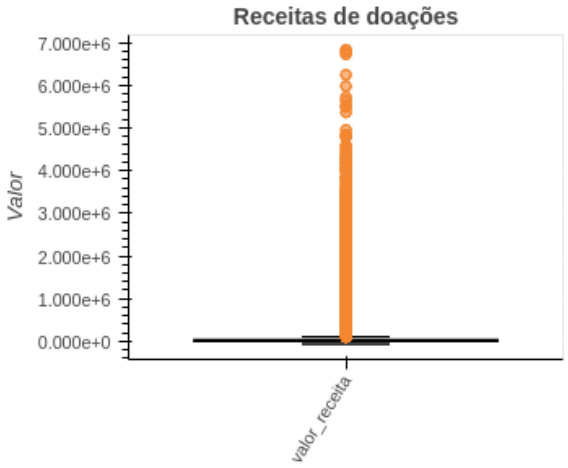

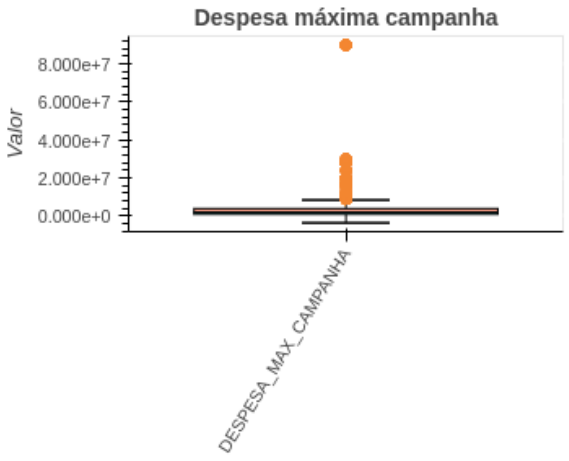

Visualização exploratória

Realizei diversas análises exploratórias para entender melhor os dados e verificar a sua relevância. A primeira análise foi verificar qual o total de doações por setor econômico, onde foi possível ver que se destaca setor não identificado, que são doações, onde não é possível saber de qual setor econômico originou a doação. Entram neste total recursos de empresas onde não foi informado o setor econômico e também recursos oriundos de pessoas físicas.

O gráfico desta análise pode ser visualizado abaixo:

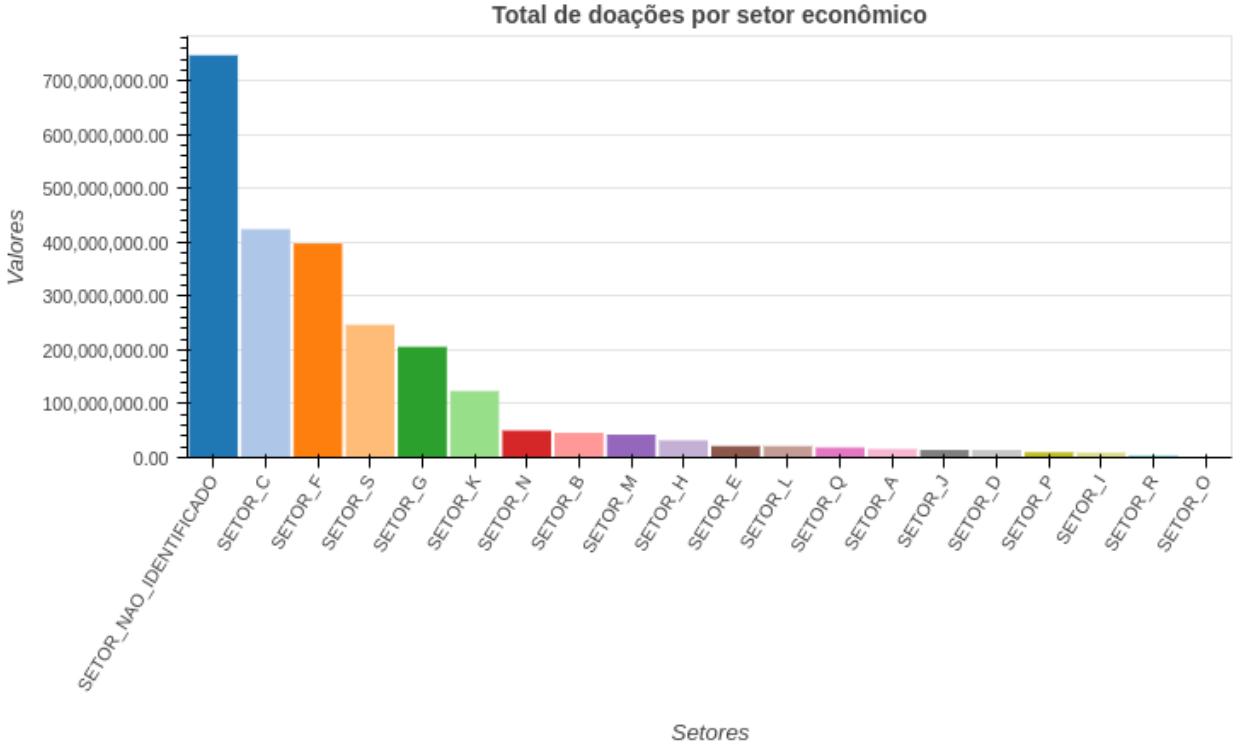

Também calculei a média de bens declarados entre todos os candidatos e os candidatos eleitos. Esta média mostrou-se superior para os candidatos eleitos, evidenciando o poder econômico na política.

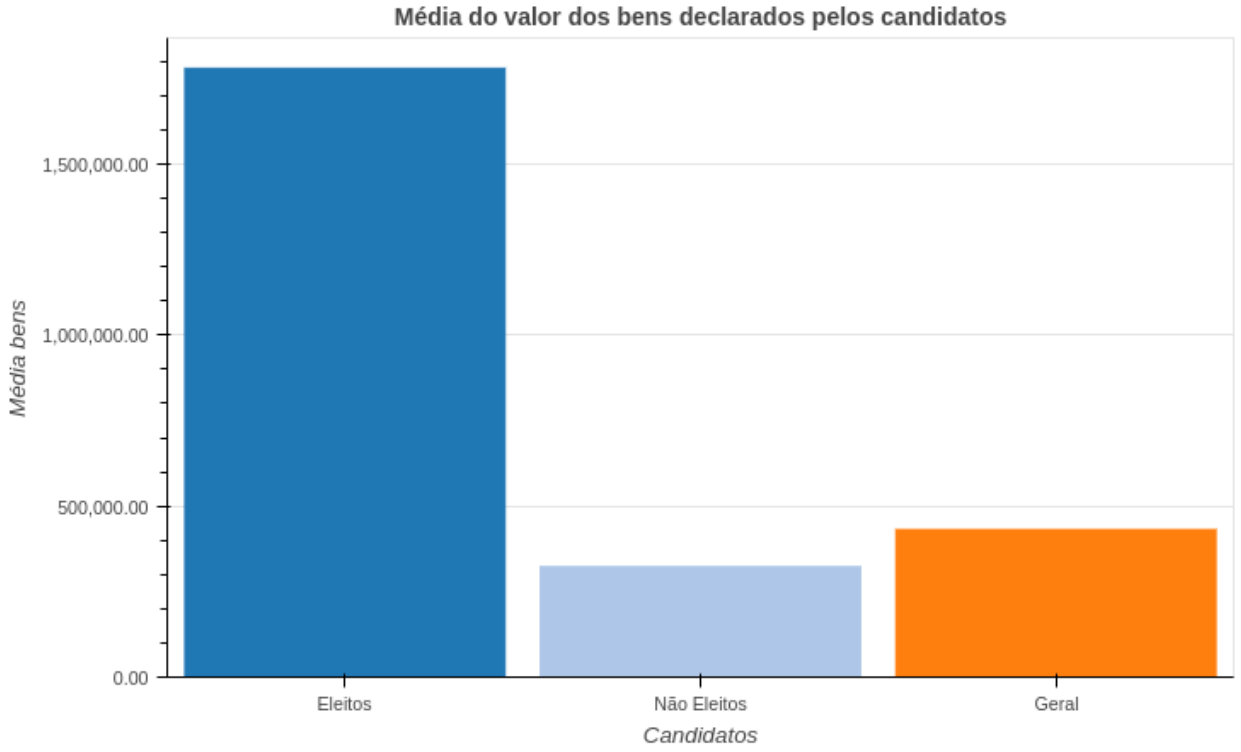

A mesma média foi calculada para o valor de doações. Mostrou a mesma relação, onde os candidatos eleitos possuem um valor de doação muito maior do que comparando com a média geral.

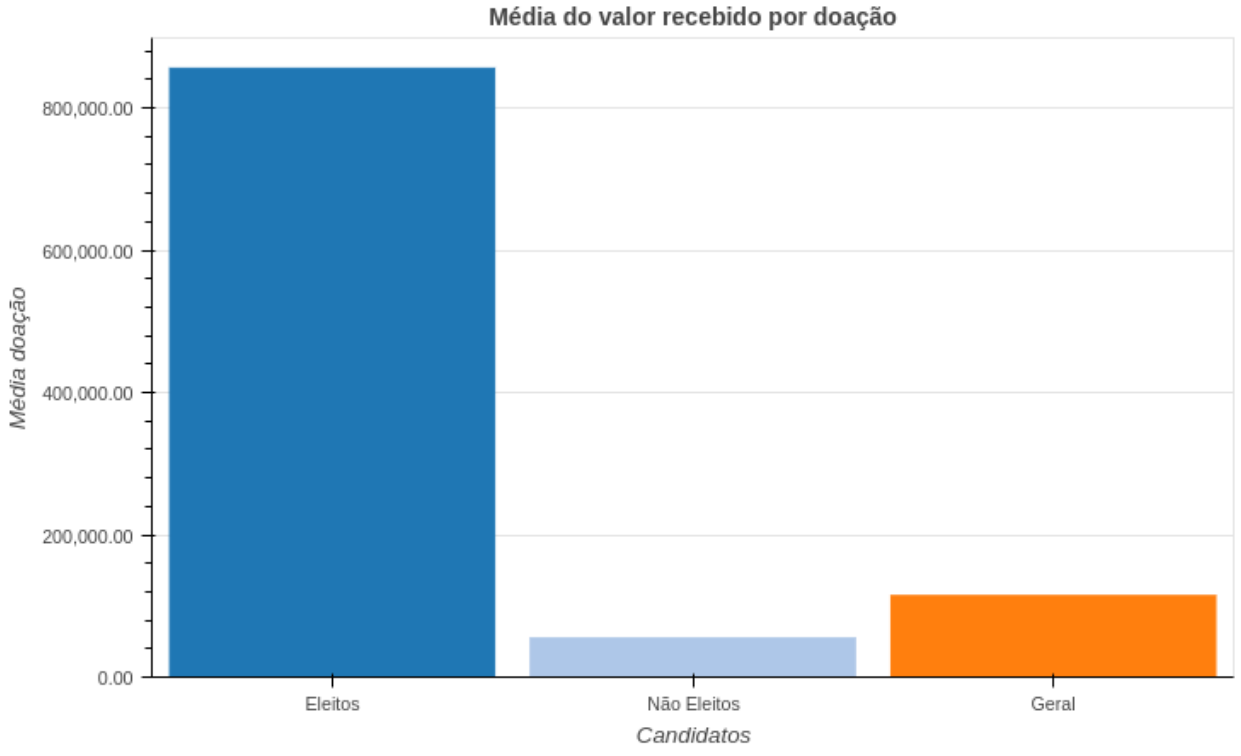

Também realizei algumas visualizações em características dos candidatos. Nestas visualizações foi possível perceber desigualdades entre gêneros e raça/cor.

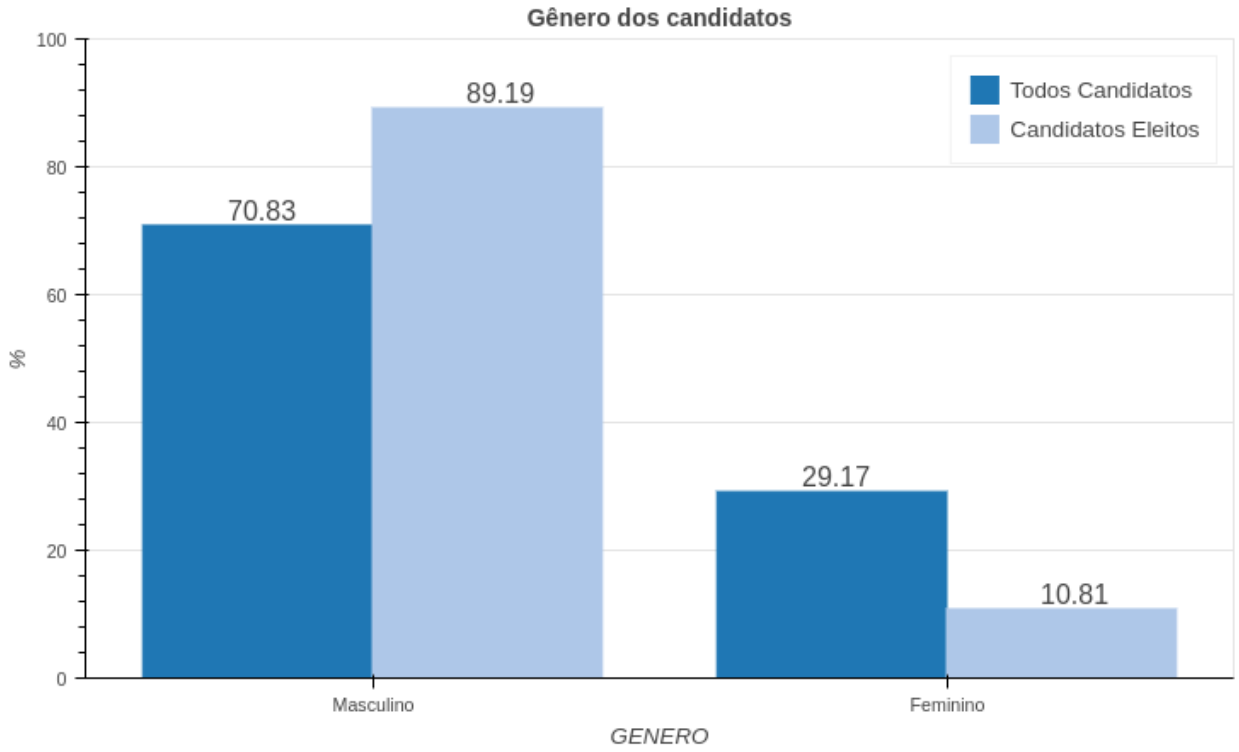

Enquanto que as mulheres correspondem a 29,17% de todos candidatos, é possível verificar uma grande diferença entre os candidatos eleitos, que correspondem a apenas 10,81%. Isso é uma confirmação da chamada “candidatura laranja”, onde mulheres são usadas apenas para preencher a cota obrigatória de participação feminina[18].

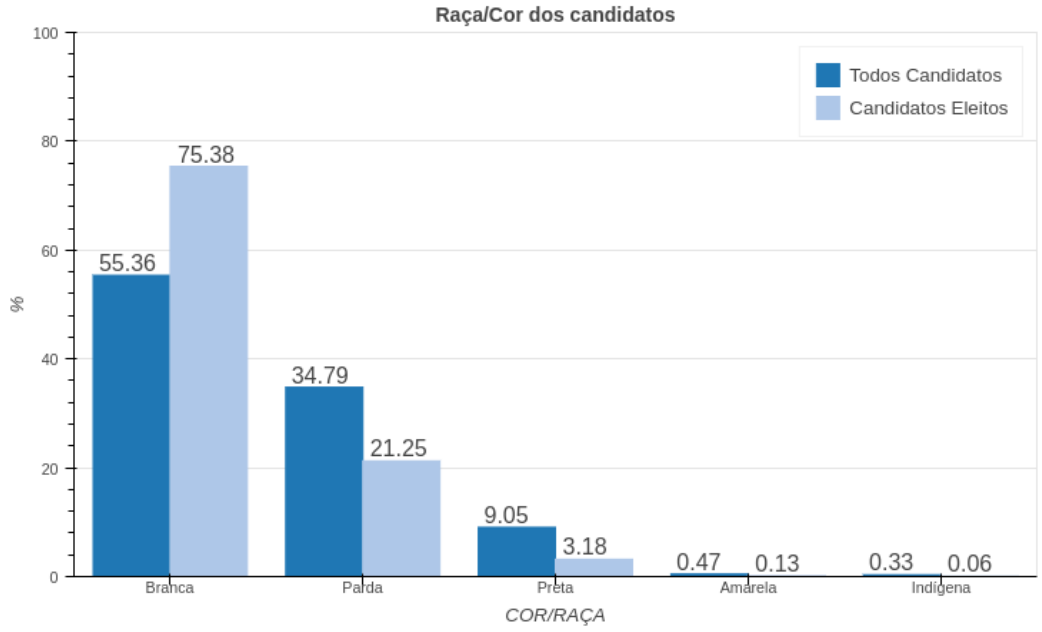

18 https://noticias.uol.com.br/politica/ultimas-noticias/2016/12/14/ministerio-publico-investiga-128-candidatas-que-nao-receberam-nenhum-voto-no-rs.htm

Os candidatos declarados como brancos correspondem a 55,36% dos candidatos, já entre os candidatos eleitos a porcentagem sobe para 75,38%. Já os candidatos declarados como pardos, correspondem a 34,79% dos candidatos e entre os eleitos essa porcentagem cai para 21,25%. O privilégio de candidatos “brancos” em detrimento de “não brancos”, configura aquilo que, em sociologia, recebeu o nome de “pigmentocracia”[19]

Outra análise feita foi no tipo de ocupação dos candidatos eleitos. Os deputados correspondem a apenas 8,14% do total das ocupações, entretanto entre os candidatos eleitos correspondem a 43,32%. Isto se deve a políticos reeleitos, evidenciando a pouca renovação política existente no país.

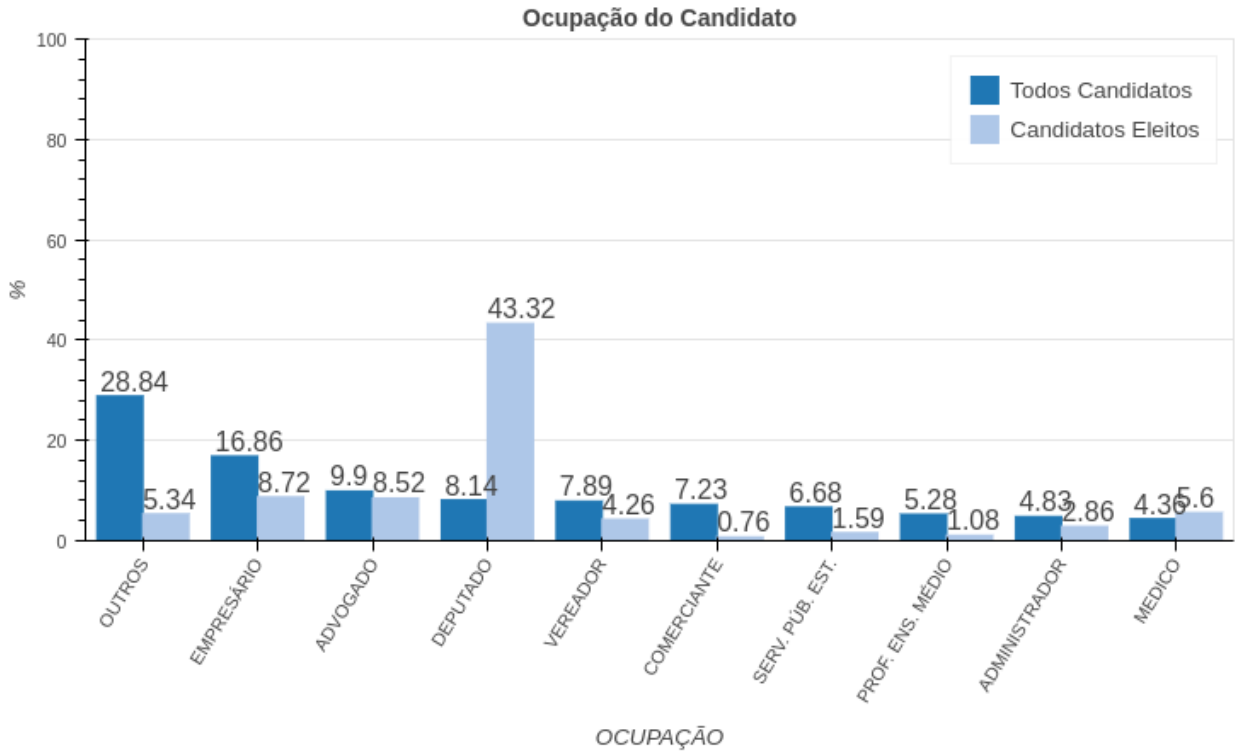

Também criei um histograma a idade dos candidatos. Em azul os candidatos eleitos sobrepondo, em vermelho, a idade dos candidatos eleitos. Para melhor visualizar os dados estão normalizados. A maior quantidade de candidatos está entre 40 e 55 anos. É possível perceber que o histograma dos candidatos eleitos está ligeiramente deslocado para a direita, mostrando que os candidatos eleitos ficam entre 45 e 60 anos.

[19] http://agencia.fapesp.br/a_desigualdade_racial_nas_eleicoes_brasileiras/25735/

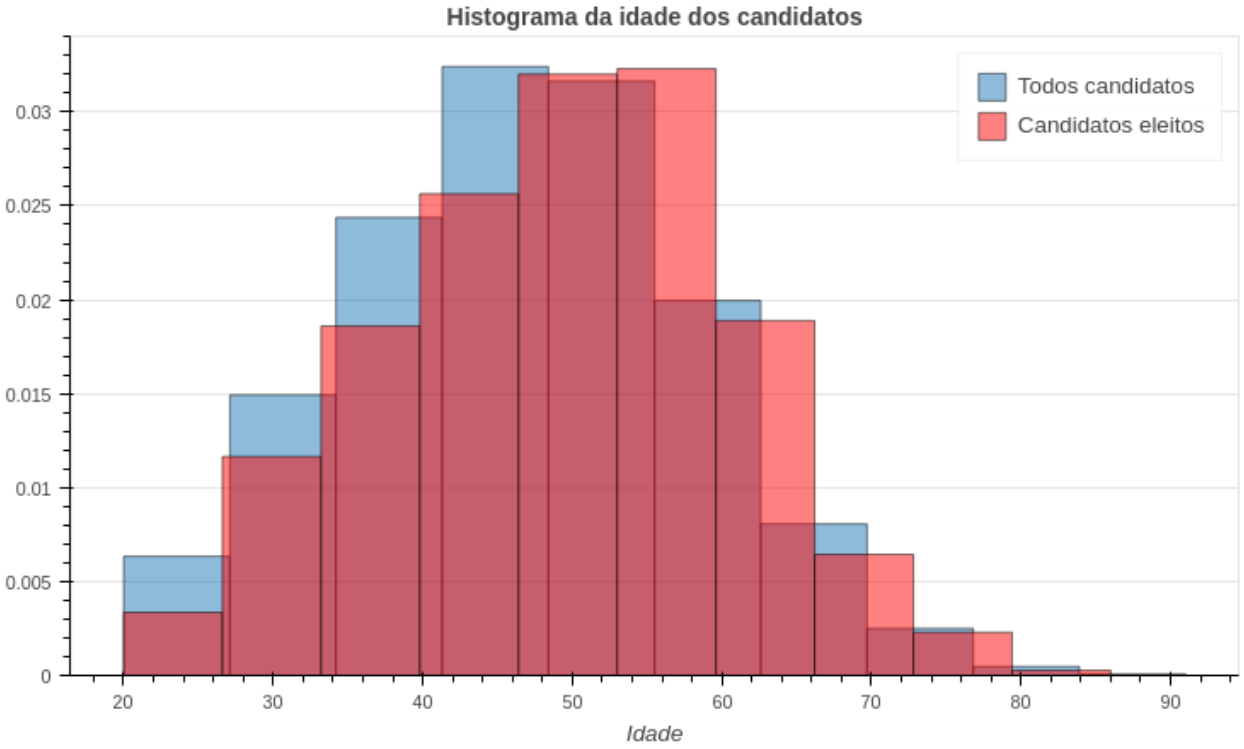

Importância dos atributos

O cálculo da importância dos atributos implementada pelo Scikit Learn é baseada no cálculo do MDI (Mean Decrease Importance)[20]. O resultado da aplicação da importância dos atributos no dataset pode ser observado no gráfico abaixo:

[20] Louppe, Gilles, et al. "Understanding variable importances in forests of randomized trees." Advances in neural information processing systems. 2013. Disponível em: https://papers.nips.cc/paper/4928-understanding-variable-importances-in-forests-of-randomized-trees.pdf

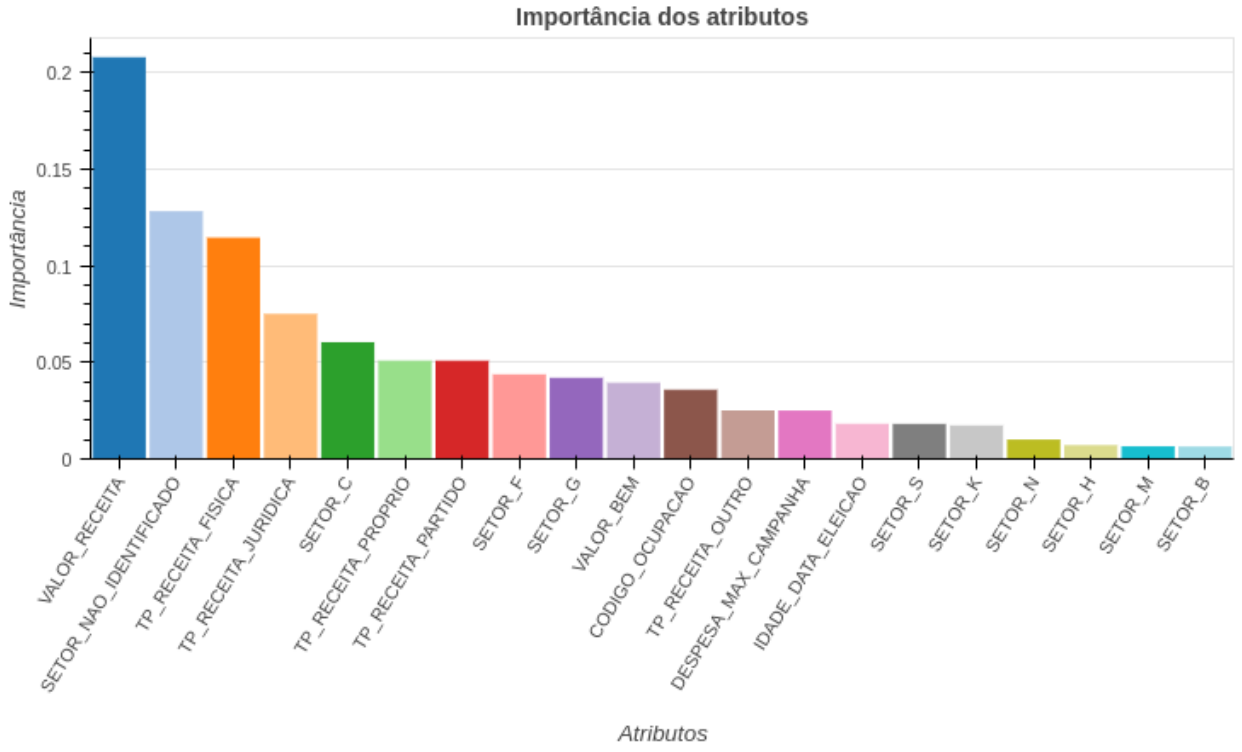

O atributo mais relevante é *VALOR_RECEITA*, isso indica que o valor total de receitas recebidas por doação possui uma grande importância para identificar se o candidato irá ou não se eleger. O segundo e terceiro atributos com maior relevância (*SETOR_NAO_IDENTIFICADO* e *TP_RECEITA_FISICA*) possuem uma relevância parecida.

Correlação dos atributos

O gráfico abaixo mostra a correlação dos atributos. Certos setores possuem alguma correlação, apesar dela não ser muito forte. Os setores C, G, F e K são os que mais parecem correlacionados. Estes setores são respectivamente: Indústria de Transformação, Comércio, Construção, Atividades financeiras.

Também é possível observar a correlação entre os setores e tipos de receitas. O atributo *SETOR_NAO_IDENTIFICADO* está fortemente correlacionado com tipo de receita de pessoas físicas e recursos próprios (o que faz sentido, pois nesse caso não é possível saber de que setor econômico este recurso provém).

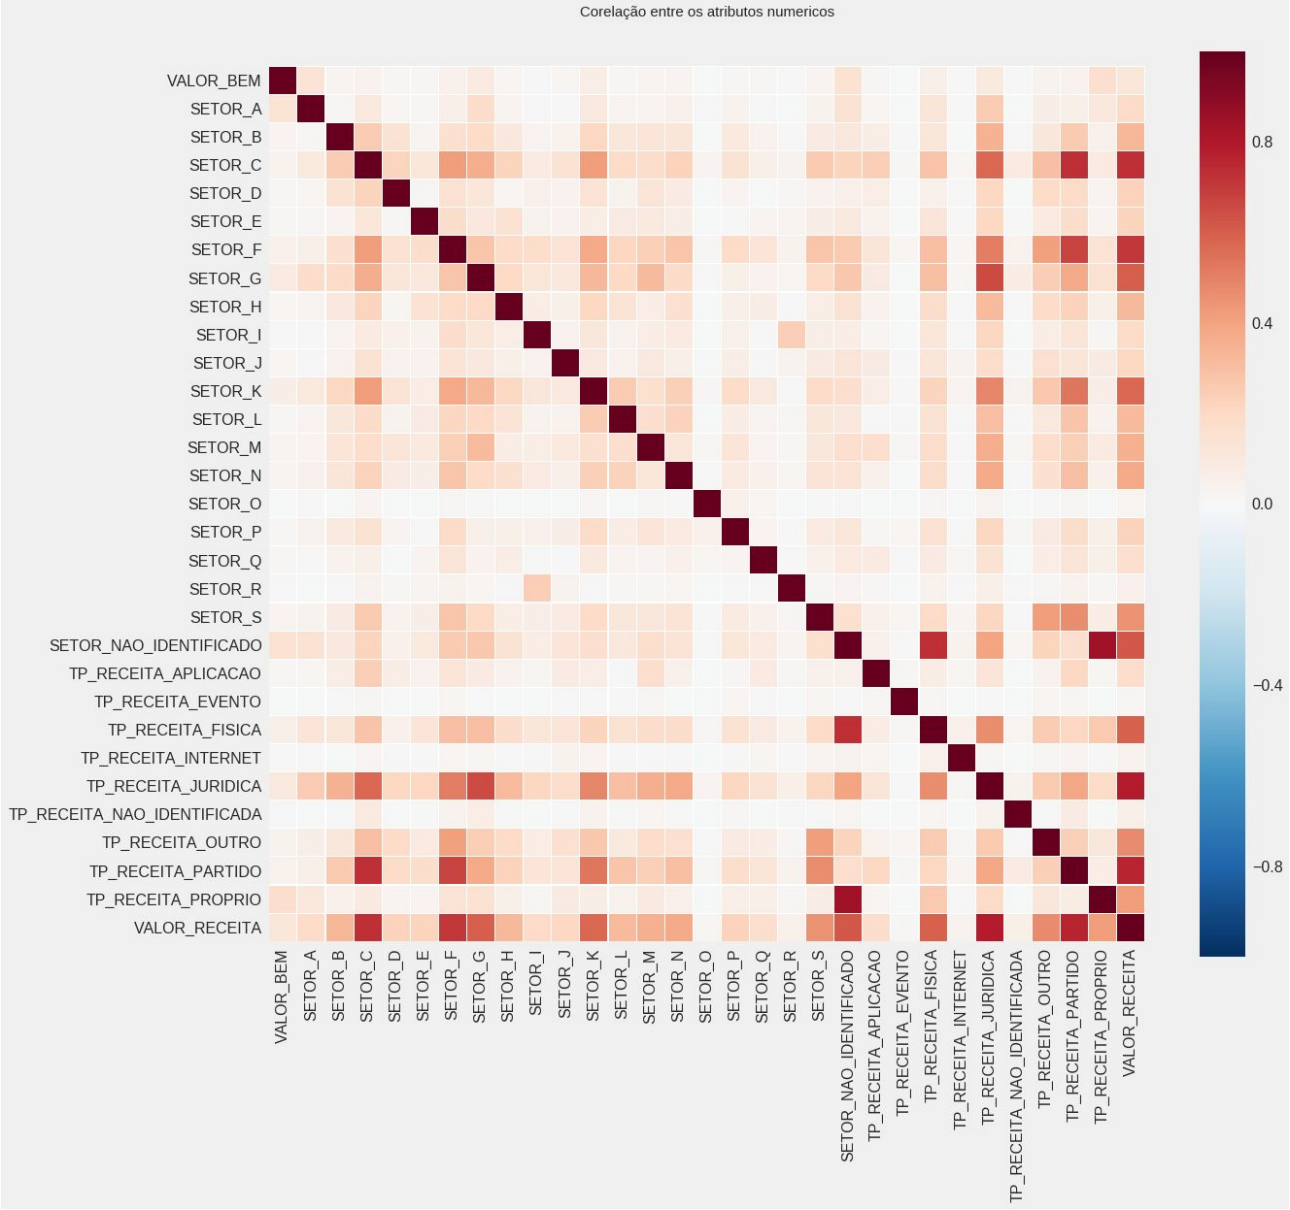

Algoritmos e Técnicas

LinearSVC

Support Vector Machines (SVMs) são métodos de aprendizagem supervisionada utilizados em classificação, regressão e detecção de outliers[21]. Support Vector Classification (SVC) é a implementação para classificação, onde as classes são separadas em um hiperplano. A melhor linha que separa as classes é a que maximiza a distância de cada classe da linha de separação. Os pontos nas linhas pontilhadas são chamados de vetores de suporte e a distância perpendicular entre as duas linhas pontilhadas é chamada de margem máxima[22].

---

[21] http://scikit-learn.org/stable/modules/svm.html#svm

[22] Joshi, Prateek. Artificial Intelligence with Python. Página 50.

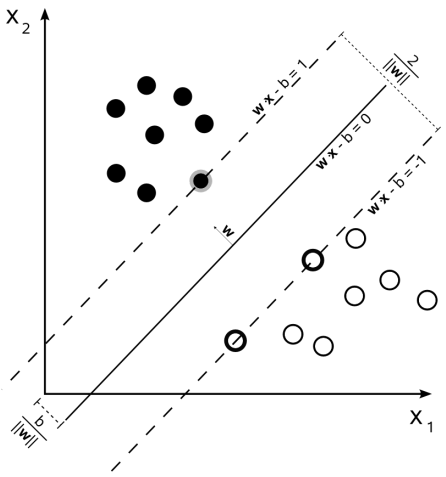

Hiperplano e margens de margem máxima para uma SVM treinada com amostras de duas classes. As amostras na margem são chamadas de vetores de suporte[23].

LinearSVC é semelhante a SVC com parâmetro kernel = 'linear', mas implementado em termos de liblinear em vez de libsvm, por isso tem mais flexibilidade na escolha de penalidades e funções de perda e deve escalar melhor para um grande número de amostras[24].

KNeighborsClassifier

O princípio por trás dos métodos vizinhos mais próximos é encontrar um número predefinido de amostras de treinamento mais próximas na distância ao novo ponto e prever o rótulo desses.

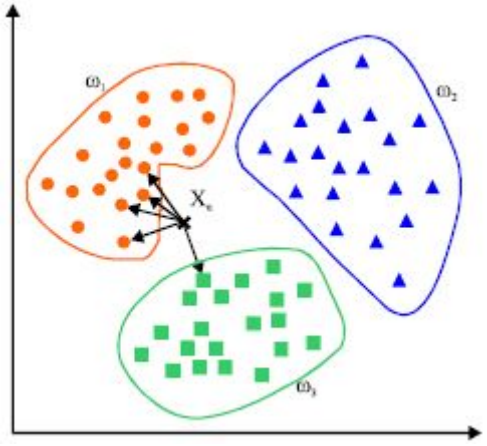

kNN classifier[25]

A classificação baseada nos vizinhos é um tipo de aprendizagem baseada em instâncias ou de aprendizagem não generalizada: não tenta construir um modelo interno geral, mas simplesmente armazena instâncias dos dados de treinamento. A classificação é calculada

[23] https://en.wikipedia.org/wiki/Support_vector_machine#Linear_SVM
[24] http://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html#sklearn.svm.LinearSVC
[25] https://www.mathworks.com/matlabcentral/fileexchange/63621-knn-classifier?focused=8662553&tab=function

a partir de um voto de maioria simples dos vizinhos mais próximos de cada ponto: um ponto de consulta é atribuído à classe de dados que tem a maioria dos representantes nos vizinhos mais próximos do ponto[26].

RandomForestClassifier

Uma árvore de decisão é uma estrutura que nos permite dividir o conjunto de dados em ramos e depois tomar decisões simples em cada nível. Isso nos permitirá chegar à decisão final ao caminhar pela árvore. As árvores de decisão são produzidas por algoritmos de treinamento, que identificam como podemos dividir os dados da melhor maneira possível[27].

Tem este nome pois sua estrutura se assemelha a uma árvore, com uma raíz e folhas. As árvores de decisão são fáceis de entender, pois criam regras de decisões. Exemplo, se (modelo do carro é X) e (cidade de emplacamento y) e (tem z anos de fabricação) e (teve k donos) então (seu preço de venda é 30000).

RandomForest é um meta estimator que se treina a uma série de classificadores de árvore de decisão em várias sub-amostras do conjunto de dados e utiliza a média para melhorar a precisão preditiva e controlar o sobreajuste[28].

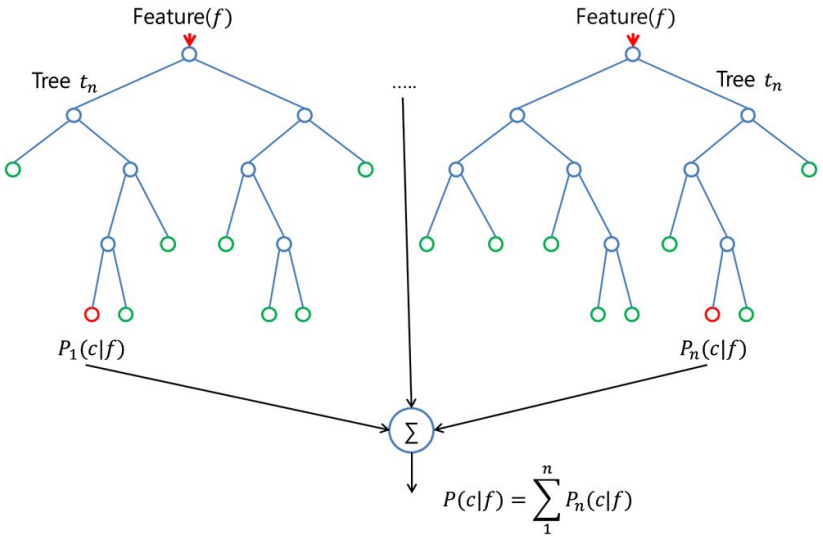

RandomForest[29]

[26] http://scikit-learn.org/stable/modules/neighbors.html#classification

[27] Joshi, Prateek. Artificial Intelligence with Python. Página 64.

[28] http://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html#sklearn.ensemble.RandomForestClassifier

[29] https://www.analyticsvidhya.com/blog/2015/06/tuning-random-forest-model/

XGBClassifier

O XGBoost é amplamente utilizado por profissionais de machine learning para criar soluções de ciência de dados de estado da arte[30], sendo um classificador muito popular em competições do Kaggle. Seu nome é a abreviatura de eXtreme Gradient Boosting.

Boosting é uma técnica de conjunto onde novos modelos são adicionados para corrigir os erros feitos pelos modelos existentes. Os modelos são adicionados sequencialmente até que nenhuma melhoria adicional possa ser feita.

Gradient boosting é uma abordagem onde são criados novos modelos que prevêem os resíduos ou erros de modelos anteriores e, em seguida, adicionados em conjunto para fazer a previsão final. É chamado de aumento de gradiente porque ele usa um algoritmo de descida de gradiente para minimizar a perda ao adicionar novos modelos[31].

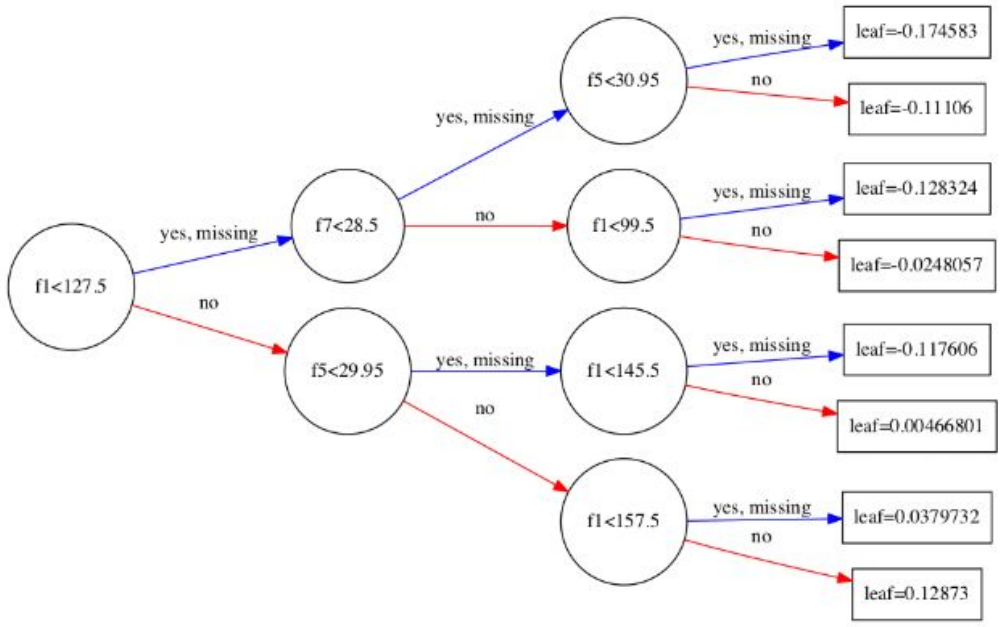

Plot a Single XGBoost Decision Tree[32]

GaussianNB

Os métodos Naive Bayes são um conjunto de algoritmos de aprendizagem supervisionados baseados na aplicação do teorema de Bayes com a suposição "ingênua" de independência entre cada par de recursos.

Teorema de Bayes com o nome do Rev. Thomas Bayes. Funciona com a probabilidade condicional. A probabilidade condicional é a probabilidade de que algo aconteça, já que

---

[30] https://github.com/dmlc/xgboost/tree/master/demo#machine-learning-challenge-winning-solutions
[31] https://machinelearningmastery.com/gentle-introduction-xgboost-applied-machine-learning/
[32] https://machinelearningmastery.com/visualize-gradient-boosting-decision-trees-xgboost-python/

alguma coisa já ocorreu. Usando a probabilidade condicional, podemos calcular a probabilidade de um evento usando seu conhecimento prévio[33].

$$P(A \mid B) = \frac{P(B \mid A)\, P(A)}{P(B)},$$

Teorema de Bayes expresso em equação matemática[34].

CondensedNearestNeighbour

CondensedNearestNeighbour é utilizado para reduzir o número de amostras e realizar o balanceamento do dataset. Ele se baseia na regra de vizinhança mais próxima para decidir iterativamente se uma amostra deve ser removida ou não. O algoritmo tem o seguinte funcionamento[35]:

1. Obtenha todas as amostras minoritárias em um conjunto C.
2. Adicione uma amostra da classe segmentada (classe a ser subestimada) em C e todas as outras amostras desta classe em um conjunto S.
3. Percorra o conjunto S, amostra por amostra e classifique cada amostra usando uma regra de 1 vizinho mais próximo.
4. Se a amostra estiver mal classificada, adicione-a a C, caso contrário, não faça nada.
5. Reiterar em S até que não haja amostras a serem adicionadas.

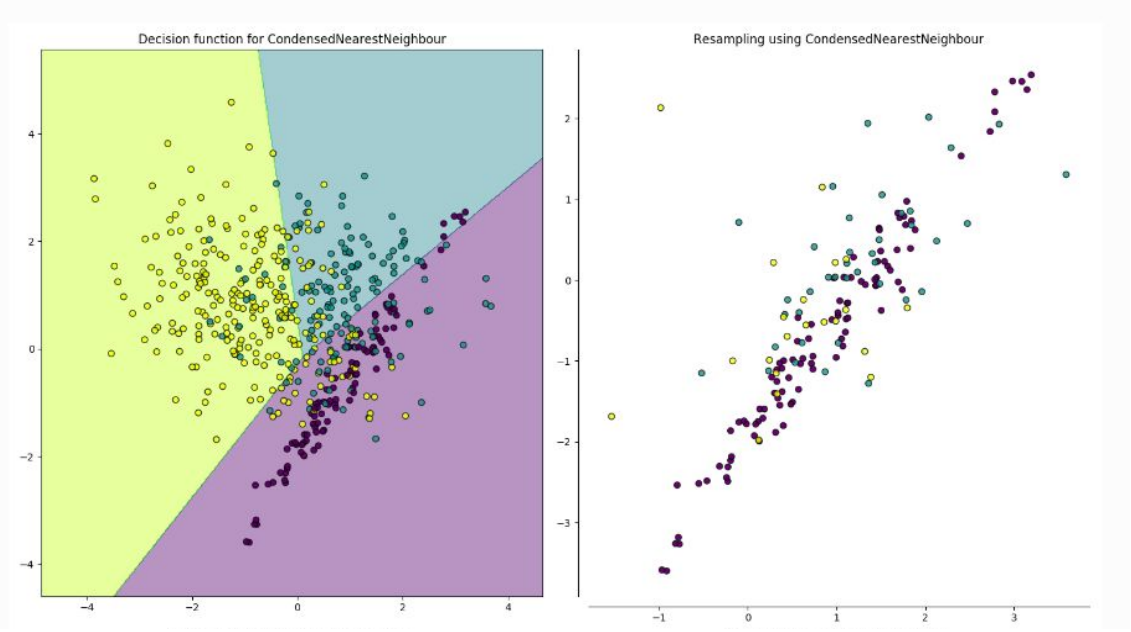

Decision function for CondensedNearestNeighbour and Resampling using CondensedNearestNeighbour

[33] http://dataaspirant.com/2017/02/06/naive-bayes-classifier-machine-learning/
[34] https://pt.wikipedia.org/wiki/Teorema_de_Bayes
[35] http://contrib.scikit-learn.org/imbalanced-learn/stable/under_sampling.html#condensed-nearest-neighbors

Benchmark

Não encontrei nenhum trabalho que utilize estes conjunto de dados com o objetivo de realizar a previsão de eleição de candidatos a deputados. Para efeitos de comparação utilizarei duas pesquisas realizadas em 2014, que indicam a intenção de votos dos eleitores. Porém deve-se levar em consideração que esta pesquisa é apenas de intenção de votos, onde não leva em conta o cálculo para a eleição do deputado. Dessa forma, eu apenas analisei os primeiros colocados, se condizem com os primeiros colocados na pesquisa de intenção, para ter uma métrica para comparar.

A primeira pesquisa analisada é a de intenção de votos, do Instituto Fonte Real, para candidatos a deputados federais de Rondônia, realizada em julho de 2014. Dos 8 candidatos eleitos, 5 estavam nos primeiros lugares na pesquisa.

A segunda pesquisa é a de intenção de votos a deputado estadual de Minas Gerais, realizada em setembro de 2014 pela DataTempo. Dos 77 candidatos eleitos, 35 estavam em primeiro lugar na pesquisa.

Calculando estes dois datasets obtive as seguintes métricas:

F1 Score: 0.49 / ROC AUC: 0.73

E também utilizando Gaussian Naive Bayes como preditor base em testes iniciais, obtive as métricas:

F1 Score: 0.55 / ROC AUC: 0.73.

III. Metodologia

Pré-processamento dos dados

Merge files

Os dados disponibilizados pelo TSE (consulta_cand_2014.zip e bem_candidato_2014.zip) possuem os dados separados em arquivos distintos por UF. Para consolidar estes arquivos criei o script “merge_files_brazil.py”. Este script consolida todos os arquivos em dois arquivos CSV: “consulta_cand_2014_Brazil.csv” e “bem_candidato_2014_Brazil.csv”. Além disso ele adiciona o cabeçalho dos atributos.

Preparação do dataset de candidatos

O dataset de candidatos possui 46 atributos com os dados pessoais de todos os candidatos a seguinte cargos: PRESIDENTE, VICE-PRESIDENTE, GOVERNADOR, VICE-GOVERNADOR, SENADOR, DEPUTADO FEDERAL, DEPUTADO ESTADUAL,

DEPUTADO DISTRITAL, 1º SUPLENTE, 2º SUPLENTE. Alguns destes atributos são irrelevantes para a análise, sendo assim os removi, resultando em 25 atributos.

Depois disso foi mantido apenas os dados dos candidatos a deputados (CODIGO_CARGO = [6, 7, 8]), com candidatura deferida ou deferida com recurso. Totalizou 21.124 candidatos, sendo 1.572 (7,44%) eleitos.

Preparação do dataset de candidatos

O dataset de bens dos candidatos possui um total de 12 atributos. Foi apenas considerado o atributo VALOR_BEM, agrupando por candidatos. Em seguida realizei o merge com o dataset dos candidatos.

Preparação do dataset de doações

Doações indiretas são quando o candidato recebe a doação de terceiros e os atributos chamados “(...) doador originário” possuem os dados do doador que fez a doação. Foi substituído aos dados do doador a informação do doador originário.

Realizei a limpeza e ajuste no dataset “Subclasses CNAE 2.2 - Estrutura.xls” disponibilizado pelo IBGE.

Com o dataset CNAE preparado, localizei os setores econômicos de cada doação. Fiz isso realizando um merge com base no atributo “Setor econômico do doador”. Apenas um setor econômico não foi localizado, onde eu atribui o setor manualmente de acordo com a descrição. As doações em que não havia informação do setor econômico eu atribui o valor “setor_nao_identificado”.

Cada setor econômico identificado de acordo com a classificação do setor econômico, realizei a soma agrupando pelo setor, para depois utilizar a função *pivot* tendo como índice o número sequencial do candidato, permitindo assim realizar o merge com o dataset de candidatos.

Também realizei a soma de acordo com o tipo da origem da receita: pessoa física, pessoa jurídica, outros, partido, internet, não identificada, recurso próprio, aplicação e eventos. Depois de realizar o *pivot*, fiz o merge com o dataset de candidatos.

Por fim realizei a soma de todas as doações, agrupando por sequencial de candidato e gerei um arquivo “dados_tratados.csv” com o dataset final para ser utilizado.

Implementation

Dados faltantes e outliers

Os datasets utilizados não possuem dados faltantes. Apenas há dados onde o candidato não declarou bens ou não houve doação, estes dados estão como nulos. O mais coerente neste caso é substituí-los por zeros.

Os outliers detectados não foram removidos. Eles não são informações erradas e possuem dados significativos para este projeto. Por exemplo, no valor da receita dentro dos outliers há 1.475 candidatos eleitos, o que equivale a 93,82% dos candidatos eleitos. Valor declarado de bens, equivale a 51,78% dos candidatos eleitos.

Separação do dataset em conjunto de treino e teste

A separação dos dados em treino e teste deve ser feito para que se tenha um conjunto de dados para validar o resultado do processo de aprendizado de máquina. Os dados de testes devem ser separados para que em nenhuma hipótese ser utilizado no processo de treinamento. Caso isso acontecer o modelo terá um ótimo score, porém em outros dados o score será significativamente baixo, pois o modelo fica super ajustado.

Antes de separar os conjuntos, foi separado o mesmo conjunto de dados da pesquisa que foi utilizado para cálculo do benchmark. Estes dados não serão utilizados no treinamento para validação do modelo final.

Para realizar esta separação do restante dos dados dois datasets de treino e teste foi utilizado *train_test_split*, de forma não estratificada, deixando 25% dos dados reservados para testes.

Testes com alguns algoritmos

Realizei alguns testes iniciais com LinearSVC, KNeighborsClassifier, RandomForestClassifier e XGBClassifier. Estes testes iniciais servem para termos uma base de qual algoritmo possui a melhor performance. O classificador GaussianNB, foi utilizado como benchmark e foi incluído nestes testes como referência.

Para realizar estes testes utilizei a função “cross_val_model”, com a utilização de *StratifiedKFold*, divide os dados de treino novamente em treino e teste, realizando várias divisões (*n_folds)*. Esta função utiliza *Score F1* para validar o modelo em cada conjunto de dados e resulta a média simples para avaliação geral do algoritmo.

Conforme o gráfico abaixo, LinearSVC e KNeighborsClassifier obtiveram o pior F1 Score, já RandomForestClassifier e XGBClassifier obtiveram melhores resultados. Estes dois classificadores tiveram resultados bem similares.

Em todos os testes que eu realizei, LinearSVC foi o que teve o resultado mais intermitente, em algumas vezes ficava melhor que KNeighborsClassifier ou RandomForestClassifer, outras vezes seu resultado ficava com F1 Score abaixo de 0,35.

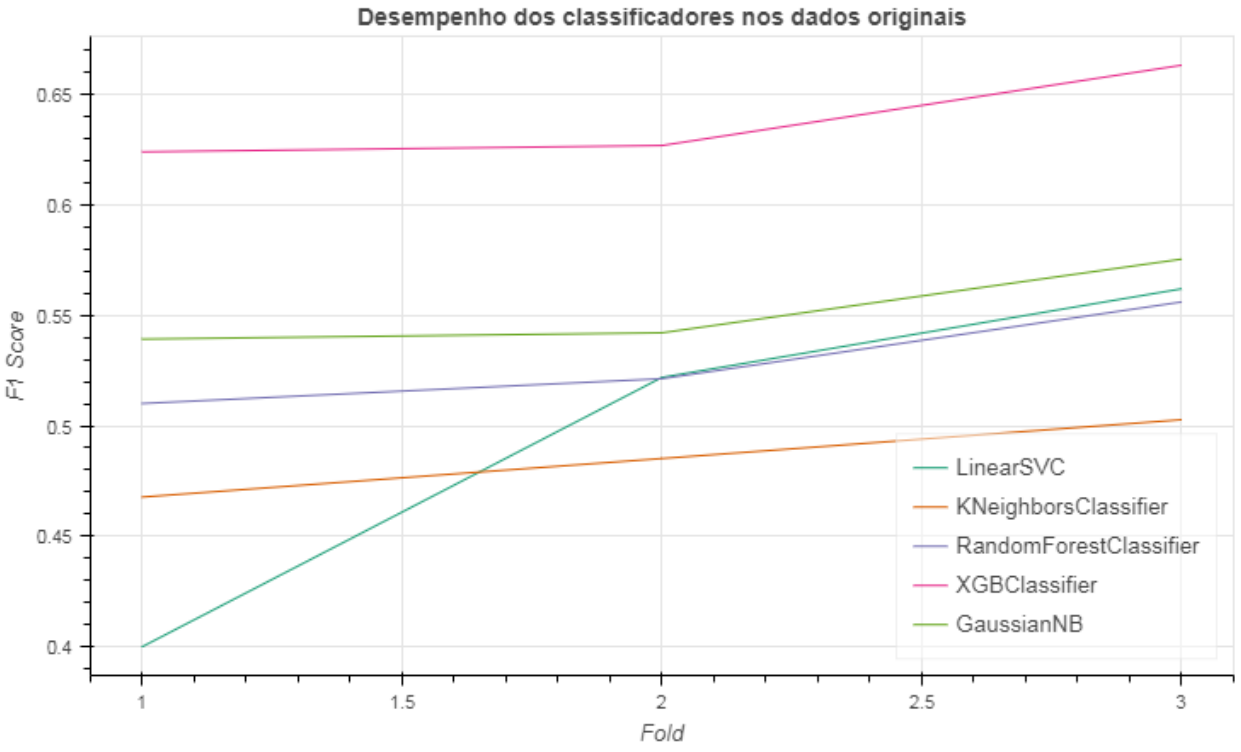

Dados desbalanceados

Dados desbalanceados são quando um tipo de classe se sobrepõe a outra em quantidade de elementos. Neste dataset a classe de candidatos eleitos correspondem a 7,44% dos dados.

Há duas formas de contornar este problema, aumentando ou reduzindo a quantidade de elementos de uma classe ou outra (*under_sampling* ou *over_sampling*).

A biblioteca *imblearn* possui alguns métodos como *RandomOverSampler*, *RandomUnderSampler, NearMiss* e *CondensedNearestNeighbour*. Realizei testes com todos estes métodos e o desempenho dos classificadores nos três primeiros métodos foram inferiores comparados com os dados originais (causando *overfitting* ou *underfitting*). O que apresentou melhor resultado foi *CondensedNearestNeighbour*, em contrapartida é o que mais tempo leva para realizar o treinamento. Este método utiliza o *nearest neighbour* para reduzir a quantidade de dados no dataset.

Este método reduziu de 15.007 amostras para 2.195, o que corresponde a 14,62% dos dados originais. No gráfico abaixo é possível ver que o desempenho dos classificadores melhoraram (exceto GausianNB):

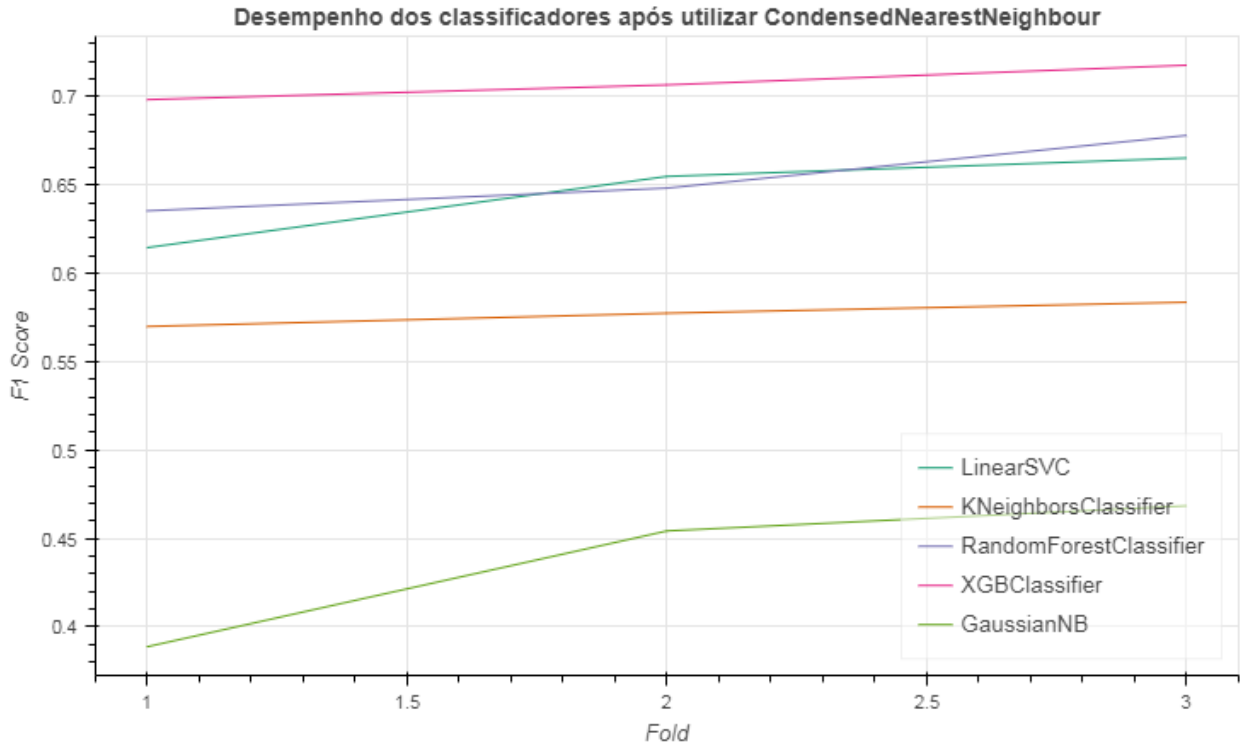

Refinamento

A parte de ajuste fino dos parâmetros é importante para obter o melhor resultado que o modelo pode oferecer. Neste trabalho, utilizo duas abordagens: RandomizeSearchCV e GridSearchCV[36].

GridSearchCV

Neste processo é definido um conjunto de parâmetros que se deseja testar o modelo. Em seguida é usado validação cruzada para avaliar a melhor combinação possível. Entretanto esta estratégia possui um elevado custo computacional. Por exemplo, a busca de 10 valores de parâmetros diferentes para cada um dos quatro parâmetros exigirá 10.000 ensaios de validação cruzada, o que equivale a 100.000 ajustes do modelo e 100.000 conjuntos de previsões se a validação cruzada de 10 vezes estiver sendo usada.

RandomizeSearchCV

Em um processo de pesquisa aleatório, é pesquisado apenas um subconjunto aleatório dos valores dos parâmetros fornecidos. Isso permite o do número de diferentes combinações de parâmetros que são testados, o que pode alterar dependendo do tempo computacional disponível.

[36] http://blog.kaggle.com/2015/07/16/scikit-learn-video-8-efficiently-searching-for-optimal-tuning-parameters/

É certamente possível que o RandomizedSearchCV não encontre um resultado tão bom quanto o GridSearchCV, mas frequentemente ele encontra o melhor resultado (ou algo muito próximo) em uma fração do tempo que GridSearchCV teria tomado, muitas vezes superando GridSearchCV.

RandomizeSearchCV no modelo RandomForest

Optei por utilizar RandomizeSearchVC no modelo RandomForest, utilizando 100 interações, com o seguinte intervalo de valores:

Parâmetros	Valores	Valor Obtido
max_depth	2, 3, 5, 10, 20, 30, None	30
max_features	st.randint(2, len(X_train.columns))	23
min_samples_split	st.randint(2, 30)	2
min_samples_leaf	st.randint(1, 11)	4
n_estimators	st.randint(5, 200)	173
bootstrap	True, False	True
criterion	"gini", "entropy"	"entropy"
class_weight	“balanced”,”balanced_subsample”, None	“balanced”

GridSearchCV no modelo XGBoost

No modelo XGBoost utilizei a abordagem descrita em “Complete Guide to Parameter Tuning in XGBoost”[37], onde o autor utiliza GridSearchCV para descobrir os melhores parâmetros, utilizando alguns passos:

1) Ajuste do número de *estimators* para *learning rate* 0.1;
2) Ajuste do *max_depth* e *min_child_weight*;
3) Ajuste do *gamma*;
4) Ajuste do *subsample* e *colsample_bytree*;
5) Ajuste do *reg_alpha*;
6) Redução do *Learning Rate para* (0.01).

O intervalo de valores utilizados foram:

[37] https://www.analyticsvidhya.com/blog/2016/03/complete-guide-parameter-tuning-xgboost-with-codes-python/

Parâmetro	Valores	Valor Obtido
n_estimators	até 1.000	601
learning_rate	0.1 e 0.01	0.01
max_depth	range(3,10,2) [2,3,4]	3
min_child_weight	range(1,6,2) [2,3,4] [4,5,6,8,10,12]	4
gamma	[0.0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9]	0.3
subsample	[0.6, 0.7, 0.8, 0.9] [0.75, 0.8, 0.85]	0.85
colsample_bytree	[0.6, 0.7, 0.8, 0.9] [0.75, 0.8, 0.85]	0.85
reg_alpha	[1e-6, 1e-5, 1e-4, 1e-3, 1e-2, 0.1, 1, 100]	0.001

IV. Resultados

Avaliação e Validação de Modelos

Com o dataset de treino foi obtido o seguinte F1 Score:

RandomForest: 0.731.

XGBoost: 0.793.

Como esperado, o desempenho nos dados de testes foi um pouco inferior. Na tabela abaixo é possível visualizar e comparar os resultados do Score F1 para cada modelo, utilizando o dataset de testes. Também é possível comparar o resultado utilizando o ajuste fino e sem utilizar.

	RandomForest		**XGBoost**	
	Sem ajustes	Com ajustes	Sem ajustes	Com ajustes
F1 Score	0.581	0.675	0.666	0.679
ROC AUC	0.796	0.851	0.850	0.857

No dataset de testes, a diferença do desempenho entre o modelo ajustado e não ajustado se mostrou mais evidente com RandomForest. Já com XGBoost houve pouca melhoria. Os dois modelos apresentam um desempenho muito parecido, com XGBoost se

mostrando um pouco melhor. Apesar da pouca margem de diferença, o melhor modelo é XGBoost. Para comparação, o modelo utilizado no benchmark (Gaussian Naive Bayes), nos dados de testes obteve o F1 score de 0.40 e ROC AUC de 0.63.

Para testar o modelo em seu limite, utilizei *train_test_split* para obter 100 conjuntos aleatórios de 10% dos dados de testes. No gráfico abaixo é possível observar o desempenho de cada classificador.

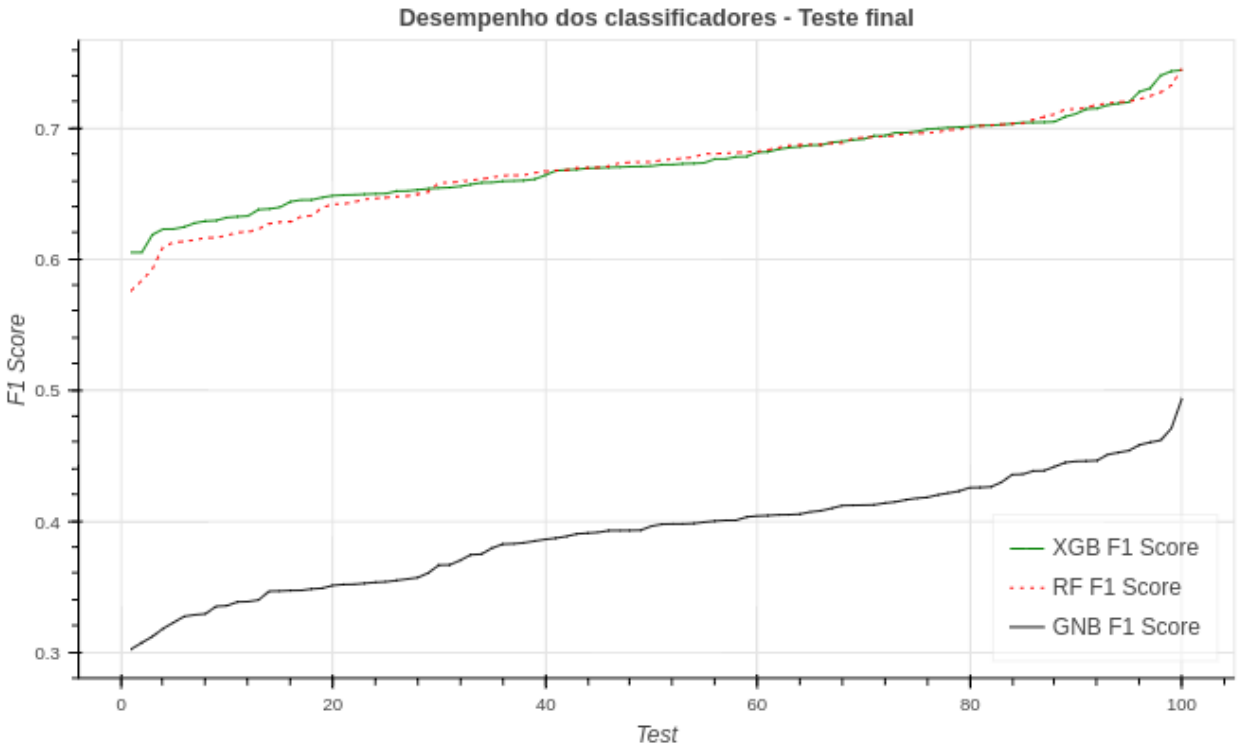

A média do F1 Score para Random Forest ficou 0.671 e XGBoost 0.673. Já Gaussian Naive Bayes 0.391.

Justificativa

Foram definidos dois benchmarks para este projeto.

No primeiro benchmark foi calculado com os dados de uma pesquisa de intenção de votos. Para comparar com este benchmark utilizei os dados separados previamente, que não fizeram parte do treino dos modelos e também não fizeram parte dos testes.

No segundo benchmark foi utilizado Gaussian Naive Bayes como um preditor básico. Na tabela abaixo é possível comparar cada resultado.

	Pesquisa	**Naive Bayes**	**XGBoost**
F1 Score	0.49	0.55	0.69
ROC AUC	0.73	0.73	0.93

Pode-se observar que o modelo XGBoost teve um resultado superior comparando tanto F1 Score como ROC AUC. Isso confirma também que este modelo pode ser utilizado como uma solução final.

V. Conclusão

Free-Form Visualization

No gráfico abaixo é possível visualizar o F1 Score do modelo, aplicado em diferentes estados. Para deputado estadual a média dos scores ficou em 0,70 e para deputado federal em 0,75.

Comparando o desempenho entre os dois cargos, é possível perceber que deputado federal, em geral, teve um desempenho melhor que para deputado estadual, com exceção de AC, MS e MA. Em outros casos, o desempenho ficou bem parecido.

A linha vermelha mostra o desempenho do Score F1 do benchmark da pesquisa (0,49). Na maioria das UF o classificador teve um desempenho melhor, exceto alguns casos, por exemplo AP, RO e AC.

É interessante relembrar que são raras as pesquisas de intenção de votos para candidatos a deputados. Um dos motivos é que a intenção de votos não está correlacionada diretamente com os candidatos vencedores. Outro motivo é que existem muitos candidatos e uma pesquisa teria que abranger uma área muito grande, elevando os custos da pesquisa.

Com base na pesquisa realizada e no cálculo do seu Score F1, este modelo se mostra superior, onde é possível ter uma noção se determinado candidato irá ou não vencer de acordo com suas características (claro que há outros fatores envolvidos que não foram abordados neste trabalho).

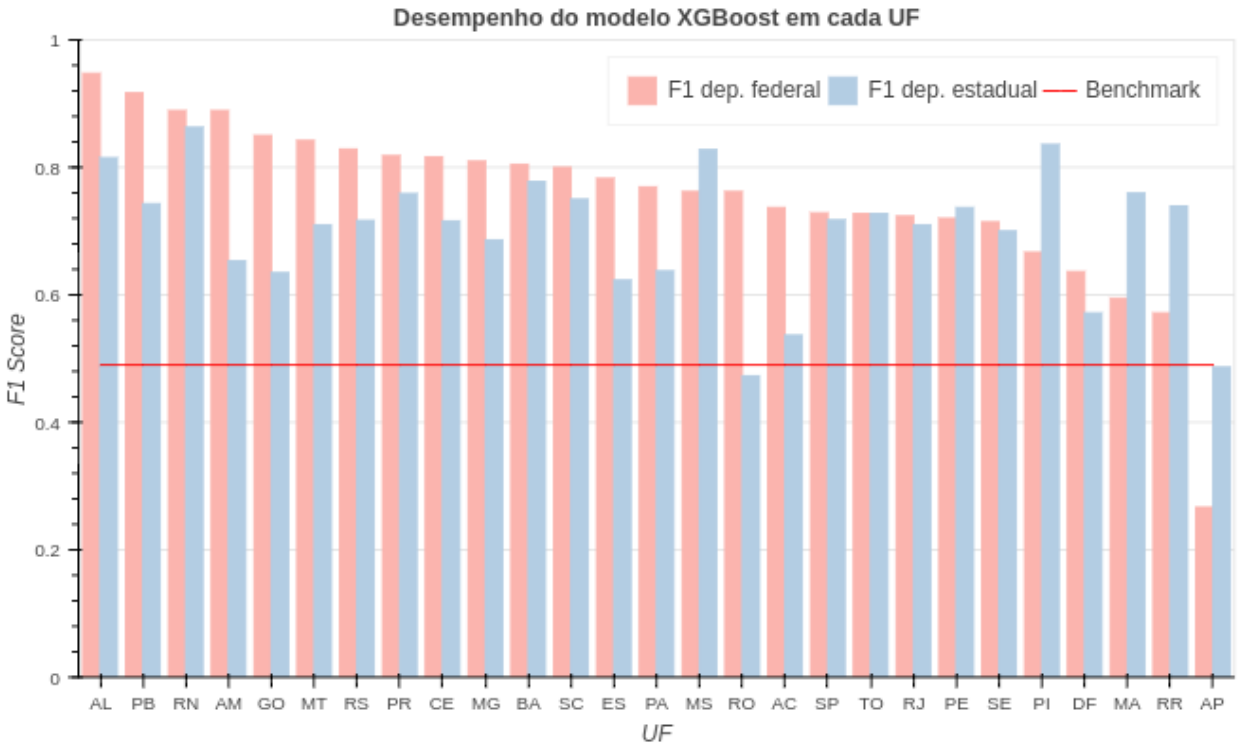

Reflexão

Parte 1 - Preparação dos dados e testes iniciais.

Ao escolher este problema para resolver fiz questão de escolher algo que utilizasse dados reais para sua resolução, onde necessitasse utilizar várias fontes de dados e que fosse algo desafiador.

O passo inicial foi testar se este problema poderia ser resolvido com Machine Learning. Procurei então por datasets que pudesse utilizar. O primeiro dataset disponível no Kaggle com os dados das doações aos candidatos já estava consolidado, facilitando o processo. Porém os datasets disponíveis no TSE não estavam, sendo o primeiro desafio escrever um script para consolidá-los.

Então quando tive os primeiros dados que poderiam ser utilizados, fiz um protótipo inicial e testei o classificador Gaussian Naive Bayes. O resultado deste classificador utilizei como benchmark. Também procurei pesquisas de intenção de votos para calcular o seu Score F1. Encontrei apenas duas pesquisas e foi onde descobri que não existem pesquisas para candidatos a deputados, por serem ineficientes e caras.

O segundo desafio na preparação dos dados foi a divisão das doações em setores econômicos, onde utilizei a tabela XLS de CNAE disponível pelo IBGE. Sua estrutura obrigou realizar um trabalho adicional para permitir sua utilização.

Com a etapa de processamento dos dados concluída, iniciei o processo de exploração dos dados. Foi aí que percebi que o processo não era linear. Em vários momentos, voltei

na etapa de preparação dos dados para realizar ajustes necessários no dataset. Esta forma não linear é o processo CRISP de mineração de dados, onde devemos gastar o máximo de tempo possível na compreensão dos negócios/mini-ciclo de compreensão dos dados, até que tenhamos uma definição concreta e específica do problema que estamos tentando resolver[38].

CRISP-DM Process diagram[39]

Parte 2 - Análise exploratória

A fase de exploração dos dados permite ter uma compreensão dos dados. Além disso, nesta fase foi onde descobri problemas que não tinha detectado anteriormente, na fase de preparação dos dados. Caso tivesse pulado diretamente para os modelos, estes problemas não seriam descobertos, possivelmente diminuindo o desempenho do modelo final.

Em um primeiro momento utilizei a biblioteca Matplotlib para gerar os gráficos para visualização. É muito fácil e rápido gerar gráficos utilizando pandas[40], isso agiliza o processo de análise. Já a biblioteca Bokeh[41] possui vários recursos e apresenta um resultado interessante, assim alterei todos gráficos para esta biblioteca.

Parte 3 - Modelos

Aqui comecei a testar os modelos LinearSVC, KNeighborsClassifier, RandomForestClassifier e XGBClassifier para ver qual possuía o melhor desempenho. Para resolver o problema de classe desbalanceadas testei o pacote imbalanced-learn. Testei os métodos RandomOverSampler, RandomUnderSampler, NearMiss e por último CondensedNearestNeighbour, que melhorou o desempenho do classificador.

---

[38] Foster Provost & Tom Fawcett. Data Science para Negócios. Página 183.

[39] Kenneth Jensen (Own work) [CC BY-SA 3.0 (http://creativecommons.org/licenses/by-sa/3.0)], via Wikimedia Commons: https://itsalocke.com/blog/crisp-dm-and-why-you-should-know-about-it/

[40] https://datasciencelab.wordpress.com/2013/12/21/beautiful-plots-with-pandas-and-matplotlib/

[41] https://bokeh.pydata.org/en/latest/

Com os dois modelos que tiveram melhores resultados iniciei o processo de ajuste de melhores parâmetros. Esta foi uma das parte difíceis e sensíveis, pois em certos momentos o modelo não apresentava bons resultados. Em um primeiro momento tentei otimizar os melhores parâmetros implementando busca aleatória com *hyperopt*[42][43]. Não satisfeito com o resultado, para o modelo RandomForest utilizei *RandomizedSearchCV*[44] e para XGBoost utilizei *GridSearchCV*, seguindo uma série de passos[45] para obter a melhor configuração. Com os parâmetros ajustados, nos testes realizados foi possível perceber que houve melhorias no classificador.

Parte 4 - Testes

É nesse momento que devemos fazer o papel de questionador. Não basta o modelo apresentar um bom resultado durante o treinamento. É necessário levá-lo ao limite, testando em dados não vistos anteriormente.

A primeira coisa a se fazer é utilizar os dados de testes para avaliar o modelo. Os dois modelos escolhidos tiveram um desempenho parecido ao final. Para escolher o melhor modelo optei por realizar 100 experimentos, dividindo o dataset de testes em pequenos pedaços aleatórios contendo 10% dos dados. Assim foi possível perceber graficamente que XGBoost levou uma pequena vantagem em comparação com RandomForest.

Também utilizei os dados da pesquisa para efetuar os testes. Estes dados da pesquisa também não estavam presentes durante o treinamento. Nesse caso, o desempenho do classificador também se mostrou superior.

Por fim, motivado pela curiosidade, separei todos os dados por UF e apliquei o modelo separadamente por tipo de cargo (deputado federal e estadual). Neste teste foi possível perceber que o modelo não eficiente em sua totalidade, porém na sua maioria o desempenho se mostrou melhor que o benchmark.

Neste trabalho em nenhum momento utilizei dados de intenção de votos, nem informações de partidos políticos. Foi possível realizar a classificação dos candidatos apenas com as suas características e informações financeiras, permitindo o modelo ser utilizado como referência ao invés da utilização de pesquisa tradicional. Fica em aberto a possibilidade de aplicar este modelo nos dados da eleição geral de 2018.

Melhorias

Este foi um trabalho que tive uma grande satisfação em concluir, pois consegui realizar várias etapas do trabalho de um cientista de dados para chegar até o modelo final.

---

[42] http://sbern.com/2017/05/03/optimizing-hyperparameters-with-hyperopt/

[43] https://github.com/felipeeeantunes/udacity_live/blob/master/porto_seguro.ipynb

[44] http://scikit-learn.org/stable/auto_examples/model_selection/plot_randomized_search.html

[45] https://www.analyticsvidhya.com/blog/2016/03/complete-guide-parameter-tuning-xgboost-with-codes-python/

Entretanto não existe um modelo perfeito e eu acredito que este trabalho pode e deve ser melhorado. Abaixo listo algumas melhorias que podem ser feitas[46]:

- Pesquisar novos datasets, incluindo de eleições passadas e a de 2018, após concluída.
- Verificar outras formas de tratar os dados desbalanceados, tratando os pesos das classes diretamente nos algoritmos.
- Criar modelos para candidatos a prefeitos e vereadores.
- Relacionar os candidatos a reeleição com os dados da candidatura anterior para testar se os gastos realizados durante o mandato refletem em sua reeleição.
- Verificar a relevância de cada candidato na internet (notícias, twitter, etc).
- Verificar a teia de doações a candidatos e como isso reflete na eleição.
- Utilizar aprendizagem não supervisionada para criar agrupamentos de tipos de empresas para criar novos atributos, não se restringindo a tabela IBGE.
- Ao invés de prever se o candidato será ou não eleito, calcular a probabilidade de ser ou não eleito.
- Criação de uma interface disponível na internet para simulação de resultado de eleição.

[46] Fique livre em utilizar este projeto como referência para novos trabalhos. Qualquer trabalho derivado obrigatoriamente deve ser público e disponível no GitHub. Fique a vontade para enviar um e-mail para eliezerfb@gmail.com a respeito de qualquer dúvida, sugestão ou para informar sobre novos resultados.